

CENTRO DE EDUCACIÓN TÉCNICA Y SUPERIOR



Aplicaciones de Minería de Datos

“Reporte”

Juan Pablo Cárdenas de Dios 13699

Prof. Miguel Ricardo Gonzalez Marquez

Ensenada, BC, a 22 de Septiembre de 2026it

1. El Espacio Vectorial de las Imágenes (Tensores y Representación Matricial)

Una computadora no ve una imagen como lo hace un ojo humano; lo procesa como una gran matriz de números. Una foto a color (RGB) de 256 x 256 píxeles está compuesta por tres capas de color superpuestas: Rojo, Verde y Azul.

Para que un algoritmo de aprendizaje automático analice la imagen, cada píxel de cada canal de color se convierte en una columna o dimensión. Matemáticamente, esto se organiza como un arreglo tridimensional (tensor) de 256 x 256 x 3. Al estirar este arreglo en una sola fila para que el modelo lo procese. Obtenemos un vector con un total de $p = 196,806$ dimensiones. Es decir, una sola foto se convierte en un punto ubicado en un espacio de casi 200,000 dimensiones.

2. El Espacio Vectorial del Texto (Procesamiento de Lenguaje Natural)

Los algoritmos pueden calcular distancias entre palabras como “Feliz” o “Triste”. Para traducir el texto a números existen dos métodos principales:

- TF-IDF (Frecuencia de Palabras): Asigna una dimensión a cada palabra existente en un vocabulario. Si la palabra aparece en el texto, se le da un valor proporcional a su rareza. La desventaja es que palabras con un significado similar (como “Feliz” y “Contento”) se tratan como dimensiones totalmente separadas y no entienden la relación entre ellas.
- Word Embeddings (Vectores Semánticos Densos): Traduce palabras o frases a un espacio de unas 300 dimensiones donde la cercanía física representa similitud de significado. En este espacio, “Feliz” y “Contento” quedan casi pegadas, permitiendo operaciones conceptuales como:

$$\text{“Rey”} - \text{“Hombre”} + \text{“Mujer”} \approx \text{“Reina”}$$

3. La Maldición de la Dimensionalidad (The Curse of Dimensionality)

Cuando el número de dimensiones p escala a miles o millones ($p \gg n$), la geometría del espacio vectorial sufre distorsiones severas:

1. Fenómeno de Equidistancia: Al aumentar las dimensiones, el “volumen” del espacio crece de forma exponencial y los datos quedan extremadamente dispersos. Sorprendentemente, la distancia entre cualquier par de datos se vuelve prácticamente constante: todos los puntos terminan estando a la misma distancia unos de otros.
2. Falla en los Algoritmos: Métodos que dependen de calcular distancias (como KNN o K-Means) pierden la capacidad de distinguir qué datos son realmente “vecinos”. Al haber tantas dimensiones y pocos datos en comparación, el modelo tiende a memorizar el ruido en lugar de aprender patrones generales (sobreajuste).